

Analise dos Dados do Sistema de Bilhetagem Eletrônica do Estado do Rio de Janeiro.

Relatório de Projeto Extensionista: Tópicos de Big Data em Python

Instituição: Faculdade Estácio de Sá - RJ (UNESA)

Curso: Tópicos de Big Data em Python (Presencial)

Aluno: José Roberto Duarte Hegendorne.

Matricula: 202502214154

Professora: Simone Gama

Período: 1º Semestre / 2026

1. Diagnóstico Teorização.

Problemática e/ou problemas identificados

O sistema de transporte público da Região Metropolitana do Rio de Janeiro movimenta diariamente milhões de passageiros através de múltiplos modais (Metrô, Ônibus, Vans, Trens e Barcas). O principal problema identificado reside na complexidade na compreensão do impacto real das políticas de subsídio tarifário (como o Bilhete Único Intermunicipal). Devido ao volume massivo de transações geradas diariamente, torna-se um desafio para a gestão pública e para as operadoras identificar padrões de uso, disparidades de custo entre diferentes linhas e possíveis anomalias ou distorções nos repasses financeiros e valores cobrados diretamente do cidadão.

b. Justificativa

A aplicação de técnicas de Big Data é indispensável neste cenário, pois permite o processamento e a análise de grandes volumes de dados brutos de bilhetagem (neste projeto, uma base diária com mais de 400.000 registros). Esta abordagem baseada em dados fornece transparência à estrutura tarifária, permitindo auditar o quanto o passageiro paga de forma líquida em comparação ao custo real da linha, validando a eficiência da distribuição dos subsídios governamentais..

OBJETIVO GERAL

Analisar o comportamento tarifário, o perfil de uso e o impacto dos subsídios no Sistema de Bilhetagem Eletrônica (SBE) do Rio de Janeiro utilizando técnicas de Big Data e modelagem estatística.

Obs: a tratativa foi realizada com dados de 1 dia de bilhetagem eletrônica, isso se dá ao fato pela limitação técnica e estrutural para fazer uma tratativa por longos períodos de tempo. Esse arquivo específico usado neste projeto foi o de menor volume encontrado.

OBJETIVO ESPECIFICO

- Realizar o saneamento, tratamento de dados nulos e engenharia de tipos da base bruta de transações públicas
- Segmentar a base de dados entre usuários de aplicações elegíveis a subsídios governamentais (ex: Vale-Transporte, Bilhete Único Expresso) e não elegíveis (ex: QR Code Unitário, Cartão Empresarial).
- Calcular métricas de estatística descritiva (média, mediana e desvio padrão) para as variáveis de custo de linha, valor transacionado e subsídio dentro de cada segmento.
- Aplicar modelos de Regressão Linear para mensurar a correlação e o poder de predição entre o valor efetivamente pago pelo passageiro e o subsidiado.
- Detectar outliers utilizando método IQR.
- Produzir Visualizações Gráficas para apoiar a interpretação dos resultados.

REFERENCIAL TEÓRICO

O projeto fundamenta-se nos pilares de Big Data aplicados ao setor público e na Governança Baseada em Dados. Utiliza os conceitos de Estatística Descritiva para sumarização de variáveis financeiras populacionais, Regressão Linear Simples para análise de correlação econômica e modelos de distribuição de frequências para identificação de assimetrias.

2. PLANEJAMENTO E DESENVOLVIMENTO DO PROJETO

Plano de Trabalho.

1. **Carga de Dados de Larga Escala:** Importação do arquivo de transações públicas (TRANSACAO_BE_PUBLICO_2026_03_22.csv)
2. **Limpeza e Saneamento Estrutural (ETL):** Eliminação de espaços em branco nos textos com `.str.strip()`, conversão de formatos de data/hora, e tratamento de decimais no padrão brasileiro (substituição de vírgula por ponto) para conversão para tipo numérico flutuante (*float*).

3. **Filtragem de Regras de Negócio:** Tratamento de valores ausentes (*NaN*) em colunas cruciais como *VI_Subsidio* e *Sentido*, além da exclusão de transações inconsistentes com valores zerados ou inválidos.
4. **Segregação por Regra de Elegibilidade:** Divisão da base principal em dois dataframes distintos (*Bu_nao_elegiveis* e *Bu_Elegiveis*) para isolar os comportamentos puramente comerciais dos comportamentos assistidos por políticas públicas de integração.
5. **Análise Descritiva e Modelagem:** Computação das matrizes estatísticas por operadora e aplicação do algoritmo de Regressão Linear através da biblioteca Scikit-Learn.
6. **Visualização Estatística:** Plotagem de diagramas de dispersão, histogramas de frequência e diagramas de caixa (*boxplots*) para validação visual dos resultados.

Grupo de Trabalho

Projeto desenvolvido individualmente por **José Roberto Duarte Hegendorne**, com atuação em todas as etapas de análise, desde a concepção do pipeline de engenharia de dados, tratamento de infraestrutura dos arquivos, até a modelagem estatística e geração de inteligência de negócios.

Detalhamento Técnico

Tema escolhido: Engenharia e Análise Estatística de Dados Financeiros do Sistema de Bilhetagem Eletrônica Metropolitana do Rio de Janeiro

Código desenvolvido: O projeto foi inteiramente estruturado e executado em Python dentro de um ambiente Jupyter Notebook. Foram utilizadas as bibliotecas Pandas e NumPy para manipulação de matrizes e higienização dos dados; Matplotlib e Seaborn para a arquitetura de gráficos e boxplots; e Sklearn.linear_model para o treinamento, extração de coeficientes e cálculo do score de determinação dos modelos preditivos.

Repositório GitHub do Projeto: <https://github.com/Heggendorn/facul>

Arquivo Jupyter notebook: *bigdata_extensionista-joseRoberto.ipynb*

bibliotecas:

- Pandas
- Numpy
- Matplotlib
- Seaborn;
- Scikit-learn

As principais etapas implementadas foram:

- Importação e tratamento de dados
- Conversão de datas e valores monetários
- Limpeza de registros inconsistentes
- Agrupamento de categoria de aplicação:
- Análise estatística;
- Regressão linear;
- Detecção de outliers;
- Geração de Gráficos;

Resultados Alcançados

Higienização e Volumetria: O processo de limpeza filtrou e validou a consistência de um volume robusto de 389.908 transações reais. A separação categórica resultou em 381.677 registros pertencentes ao grupo de benefícios e integrações (*Elegíveis ao bilhete único/subsídio*), e 8.231 registros de tarifas de balcão ou comerciais (*Não Elegíveis*).

Análise Descritiva comparativa

Grupo Não Elegíveis: Apresentou uma tarifa média de **R\$ 7,06** e mediana de **R\$ 7,90**. Obedecendo rigorosamente à regra de negócio comercial, a média e o desvio padrão do subsídio foram estatisticamente de **R\$ 0,00**, comprovando que o usuário arca com 100% do custo tarifário.

Grupo Elegíveis: Evidenciou o impacto direto do subsídio estatal. O custo médio nominal das linhas utilizadas por este grupo foi de **R\$ 9,72**. No entanto, o valor médio transacionado (debitado do cidadão) foi reduzido para **R\$ 7,52** (com mediana de R\$ 6,70), impulsionado por um aporte médio de subsídio público de **R\$ 2,19** por validação (desvio padrão de R\$ 3,27).

Distribuição de Frequência e Outliers: A análise de distribuição mostrou uma forte concentração de transações na faixa de R\$ 5,00 a R\$ 8,50 (composta majoritariamente por modais urbanos como o Metrô a R\$ 7,90 e Barcas a R\$ 5,00). Os diagramas de caixa (*boxplots*) identificaram *outliers* extremos com valores de tarifas que ultrapassam os R\$ 50,00 no setor comercial (como na Viação Cidade do Aço, que registrou média atípica de R\$ 33,77 e máxima de R\$ 58,10) e picos isolados de até R\$ 228,51 no grupo elegível, característicos de frotas intermunicipais rodoviárias de longo curso.

Regressão Linear e correlação

Para o grupo Não Elegível (ex: Cartão Empresarial), a regressão linear alcançou um coeficiente de determinação R^2 de 1.0000 (100%), indicando que a linha reta do modelo descreve perfeitamente o fenômeno: o valor pago possui relação direta, linear e idêntica de 1 para 1 com o valor da linha.

Para o grupo Elegível (ex: Bilhete Expresso), a regressão linear resultou em um coeficiente angular de -0.1812 e um R^2 de 0.0341 (3,4%). Este baixo poder de explicação linear demonstra cientificamente a complexidade do sistema de transporte: o valor final pago pelo trabalhador nas catracas não aumenta de forma proporcional ou linear ao custo da linha, pois sofre

interferência direta das regras variáveis de desconto, limites de integração e tetos de subsídios do Bilhete Único.

ENCERRAMENTO DO PROJETO

Conclusão Social: A quebra de linearidade da curva tarifária gerada pelo Bilhete Único não é uma falha estatística; é a representação exata de uma **política pública eficiente**. Ela garante que o custo de morar longe dos centros urbanos não inviabilize o sustento do cidadão, transformando o transporte em um direito de acesso ao trabalho e à renda, porém, uma participação maior do estado reduzindo o valor máximo pago para os elegíveis, diminua o custo para esse grupo de contemplados.

Conclusões das Análises:

A consolidação dos dados de Big Data revela a arquitetura e o comportamento da mobilidade fluminense sob a ótica financeira. O volume de transações evidencia o Metrô de Janeiro (Concessão Metroviária) como um pilar central de transporte de massa, registrando volumes superiores a 105.000 validações no grupo assistido. No transporte rodoviário, grandes empresas da Baixada Fluminense (como a Empresa de Transportes Flores, com mais de 25.000 registros) demonstram o imenso fluxo de passageiros periféricos que se deslocam diariamente para os centros econômicos.

A análise comprova que, sem a política de subsídios intermunicipais e o uso do Vale-Transporte, o custo de deslocamento seria proibitivo para grande parte da população, dado que as tarifas nominais das linhas rodoviárias periféricas são consideravelmente mais elevadas (médias superiores a R\$ 12,00 em operadoras como a Auto Viação Reginas) quando comparadas aos modais estritamente urbanos. O Big Data permitiu mapear com precisão onde o recurso público de subsídio é mais exigido para equilibrar essa balança socioeconômica.

4. CONSIDERAÇÕES FINAIS

O desenvolvimento deste projeto comprovou a viabilidade e a robustez da utilização do Python e de ferramentas de Big Data na auditoria e fiscalização de grandes sistemas de bilhetagem eletrônica metropolitana. O processo de ETL foi essencial, expondo um volume expressivo de dados duplicados ou redundantes (72.368 linhas removidas) que poderiam distorcer análises financeiras se não tratados adequadamente.

A modelagem por regressão cumpriu um papel analítico fundamental, não para predição direta, mas para provar matematicamente a forte quebra de linearidade provocada pelas regras de benefícios sociais no transporte.

Como recomendação para o aprimoramento de políticas públicas e futuros estudos, sugere-se o cruzamento desta base financeira com dados de geolocalização dos validadores (coordenadas de GPS), permitindo correlacionar os custos e subsídios aqui mapeados com a distância real em quilômetros e o tempo de viagem dos passageiros nas vias do Rio de Janeiro.