

ANÁLISE ESTATÍSTICA DE DADOS FINANCEIROS DO SISTEMA DE BILHETAGEM ELETRÔNICA METROPOLITANA DO RIO DE JANEIRO (RIOCARD)

RELATÓRIO DE PROJETO EXTENSIONISTA

Aluno: José Roberto Duarte Hegendorne

Matrícula: 202502214154

Professora Orientadora: Simone Gama

Período Acadêmico: 1º Semestre / 2026

1. DIAGNÓSTICO E TEORIZAÇÃO

1.1 Problemática e Problemas Identificados

O sistema de transporte público coletivo da Região Metropolitana do Rio de Janeiro se caracteriza por uma alta complexidade operacional, movimentando diariamente milhões de passageiros através de múltiplos modais integrados, tais como Metrô, Ônibus Urbanos, Vans Cadastradas, Trens (Supervia) e Barcas. A principal problemática identificada neste cenário reside na opacidade e na dificuldade técnica de compreensão do impacto real exercido pelas políticas de subsídio tarifário. Devido ao volume massivo de microtransações geradas diariamente, constitui um desafio crítico para os órgãos de controle da gestão pública, para a sociedade civil e para as próprias operadoras a identificação clara de padrões de uso, disparidades de custo entre linhas periféricas e centros urbanos, bem como a detecção de potenciais anomalias, redundâncias ou distorções nos repasses financeiros e valores cobrados diretamente do usuário final.

1.2 Justificativa

A aplicação de técnicas avançadas de Big Data e Engenharia de Dados faz-se indispensável neste contexto, visto que métodos tradicionais de amostragem e análise são incapazes de processar de forma tempestiva os grandes volumes de dados brutos gerados pela bilhetagem eletrônica (a base processada registrou uma movimentação superior a 1.086.118 transações por dia nos três dias útil da semana). Esta abordagem analítica fundamentada em dados em larga escala fornece transparência à estrutura tarifária metropolitana, permitindo auditar o valor efetivamente pago pelo passageiro de forma líquida em comparação ao custo contratual da linha executada. Consequentemente, viabiliza-se a validação científica da

eficiência socioeconômica na distribuição dos subsídios governamentais, assegurando a modicidade tarifária e a otimização dos recursos públicos.

1.3 Referencial Teórico

O projeto ancora-se nos pilares conceituais de Big Data aplicados ao setor público e na Governança Baseada em Dados

. Utiliza os fundamentos de Estatística Descritiva para a sumarização, centralidade e dispersão de variáveis financeiras populacionais, técnicas de detecção de *outliers* através do Intervalo Interquartil (IQR), e o modelo de Regressão Linear Simples para a análise de correlação e modelagem preditiva do impacto econômico tarifário.

2. OBJETIVOS DO PROJETO

2.1 Objetivo Geral

Analisar o comportamento tarifário, o perfil de uso por turnos operacionais e o impacto financeiro dos subsídios no Sistema de Bilhetagem Eletrônica (SBE) do Estado do Rio de Janeiro por meio do emprego de técnicas de Big Data, engenharia de dados e modelagem estatística preditiva. *Nota Metodológica:* O processamento e tratamento analítico foram realizados com microdados públicos correspondentes aos três primeiros dias úteis da semana operacional (de 16/03/2026 a 18/03/2026), devido às restrições técnicas, estruturais e computacionais para a manipulação local de séries históricas mais longas em Big Data.

2.2 Objetivos Específicos

- Executar o pipeline de ETL (Extração, Transformação e Carga), realizando o saneamento, tratamento de dados nulos, remoção de registros inconsistentes e engenharia de tipos sobre a base bruta de transações públicas;
- Segmentar a base consolidada entre perfis de uso comerciais específicos, dividindo os usuários entre os que efetuam o Pagamento Integral da tarifa e os que usufruem de Benefícios/Subsídios Governamentais (Gratuidades e Integrações);
- Calcular métricas de estatística descritiva (média, mediana, desvio padrão e coeficiente de variação) para as variáveis de custo de linha, valor transacionado e subsídio dentro de cada grupo;
- Aplicar modelos de Regressão Linear Simples para quantificar a taxa de variação e a correlação entre a tarifa cheia cobrada e o subsídio aportado pelo Estado;
- Detectar anomalias e *outliers* na distribuição de preços de linhas por meio do método estatístico IQR;
- Desenvolver visualizações gráficas de alta densidade informativa para apoiar a interpretação dos resultados técnicos obtidos.

3. PLANEJAMENTO E DESENVOLVIMENTO DO PROJETO

3.1 Plano de Trabalho

O desenvolvimento do projeto seguiu rigorosamente o pipeline técnico de Big Data estruturado em seis fases sucessivas:

1. **Carga de Dados em Larga Escala:** Importação programática dos arquivos de transações públicas diárias diretamente de arquivos compactados (TRANSACAO_BE_PUBLICO_2026_03_16.csv.zip a 2026_03_18.csv.zip), otimizando o uso de memória do ambiente de execução;
2. **Limpeza e Saneamento Estrutural (ETL):** Higienização de strings através da eliminação de espaços em branco marginais com `.str.strip()`, tratamento de inconsistências de formatação regional de moedas (conversão de vírgula para ponto) e tipagem correta de dados numéricos para float;
3. **Filtragem de Regras de Negócio:** Tratamento de valores ausentes (*NaN*) em colunas cruciais, validação cronológica dos registros por arquivo e exclusão de transações inconsistentes com valores tarifários nulos ou inválidos;
4. **Segregação por Regra de Elegibilidade:** Divisão da base principal em DataFrames específicos de análise (*Pagamento_Integral* e *Com_Subsidio*), isolando o comportamento puramente de mercado das políticas de assistência social e integração metropolitana;
5. **Análise Descritiva e Modelagem Preditiva:** Computação das matrizes estatísticas de centralidade, agrupamentos por turnos e treinamento do algoritmo de Regressão Linear Simples via biblioteca Scikit-Learn;
6. **Visualização Estatística:** Geração de diagramas de dispersão, histogramas de frequência bimodal e diagramas de caixa (*boxplots*) utilizando Matplotlib e Seaborn para validação visual dos resultados.

3.2 Grupo de Trabalho e Detalhes Técnicos

O projeto de extensão universitária foi conduzido de forma estritamente individual pelo aluno José Roberto Duarte Hegendorne, atuando em todas as frentes de engenharia, estatística e modelagem de dados

. O ambiente tecnológico foi composto por Python 3 desenvolvido no VSCODE, com uso complementar do repositório GitHub para versionamento de código (<https://github.com/Heggendorn/facul>) e do arquivo Jupyter Notebook (*bigdata_extensionista-joseRoberto.ipynb*), Claude IA para referencial teórico. As bibliotecas-chaves empregadas foram pandas e numpy para processamento matricial, re para expressões regulares de limpeza de hashes, os e zipfile para gerenciamento de arquivos em disco, além de matplotlib.pyplot, seaborn e sklearn.linear_model.

Repositório GitHub do Projeto: <https://github.com/Heggendorn/facul>

4. RESULTADOS ALCANÇADOS

4.1 Higienização, Volumetria e Estatística Descritiva Geral

O processo de ETL e descontaminação validou a consistência de um volume robusto de **3.258.355 transações reais**, expurgando um total de 1.259.873 linhas inconsistentes, em sua maioria resíduos de transações ocorridas em datas desalinhadas com os dias específicos analisados. O sistema movimentou, na amostragem de 3 dias, um montante financeiro total de **R\$ 32.528.182,91**, apresentando uma estabilidade de demanda diária de 1.086.118 transações. Criou-se uma engenharia de recursos para classificar os perfis de transação através do campo Perfil, agrupados no campo Grupo_Pagamento para distinguir as naturezas comerciais. A análise descritiva dos grupos revelou:

- **Grupo Pagamento Integral:** Composto por transações onde a tarifa nominal da linha equivale exatamente ao valor debitado (ex: QR Code unitário do Metrô, Cartão Empresarial), sem participação estatal (VI_Subsidio = 0). Apresentou uma tarifa média de R\$ 8,76, mediana de R\$ 7,10 e desvio padrão do subsídio estatisticamente nulo (R\$ 0,00), comprovando que o usuário arca com 100% do custo;
- **Grupo Com Subsídio / Integração:** Composto por usuários beneficiados por políticas assistidas (Gratuidade, Bilhete Único Intermunicipal, Integrações). O custo médio nominal das linhas utilizadas por este grupo foi de R\$ 11,51. Contudo, o valor médio transacionado (debitado do cidadão) caiu para R\$ 5,67 (mediana de R\$ 5,00), impulsionado por um aporte médio de subsídio público de **R\$ 5,82 por validação** (desvio padrão de R\$ 4,02).

4.2 Distribuição de Frequência por Turnos Operacionais

O fluxo volumétrico de viagens apresentou um comportamento bimodal regular e estável ao longo dos três dias estudados, dividindo-se nas seguintes faixas de demanda:

- **Pico Tarde (16h às 19h):** Destacou-se como o turno de maior saturação do sistema de transportes, concentrando entre **31,35% e 31,81%** de toda a movimentação diária (volume absoluto de 336 mil a 349 mil viagens/dia). Apresentou o maior Coeficiente de Variação (CV de 1,93%), denotando alta sensibilidade a fatores externos diários (condições de tráfego, clima e oscilações de jornadas comerciais);
- **Pico Manhã (06h às 08h):** Posicionou-se como o segundo período de maior pressão sobre o sistema, absorvendo de **24,9% a 25,1%** do volume diário (267 mil a 276 mil viagens), com CV estável de 1,66%;

- **Entre Pico Diurno (09h às 15h) e Noite/Madrugada:** Apresentaram demandas residenciais constantes e equilibradas, respondendo cada turno por aproximadamente 21,5% a 22,2% do total de validações. O Entre Pico Diurno demonstrou ser o período de maior previsibilidade sistêmica, com o menor índice de variação entre os dias (CV de apenas 0,63%).

5. MODELAGEM PREDITIVA: REGRESSÃO LINEAR

Para mensurar a correlação matemática e o impacto financeiro das variações de tarifas sobre o orçamento público, aplicou-se a modelagem por Regressão Linear Simples sobre o grupo de usuários assistidos (*Com_Subsidio*).

5.1 Configuração do Modelo

O modelo foi estruturado para prever o comportamento do subsídio frente aos custos nominais fixados para as linhas de transporte público:

- **Variável Independente (X):** VI_Linha (Preço nominal total da tarifa da linha)
- **Variável Dependente (Y):** VI_Subsidio (Valor do subsídio a ser pago pelo governo)

5.2 Resultados e Parâmetros Estatísticos

Após o processamento e convergência do algoritmo com os dados do perfil de interesse, o modelo reportou os seguintes parâmetros estatísticos oficiais:

- **Coefficiente Angular (Inclinação da Reta):** 0.6499
- **Intercepto (Coeficiente Linear no Eixo Y):** -2.1285
- **Coefficiente de Determinação (R^2):** 0.6601
- **Erro Quadrático Médio (MSE):** 4.2928

A função linear gerada pelo algoritmo que dita o comportamento preditivo do subsídio é expressa pela equação:

$$\text{Valor do Subsídio (R\$)} = (0.6499 \times \text{Valor linha}) - 2.1285$$

5.3 Análise e Interpretação Qualitativa

O Coeficiente de Determinação (R^2) de 0,6601 indica que o modelo possui uma alta capacidade de explicação para uma análise linear simples de linha única

. Exatamente **66,01% de toda a variação ocorrida nos valores dos subsídios estatais** é determinada e explicada diretamente pelo valor cheio fixado para a linha (VI_Linha).

Os 33,99% restantes da variação decorrem de regras de negócio de integração intermodal complexas (combinação de diferentes modais e tarifas teto) que não seguem uma proporcionalidade estritamente linear.

O Coeficiente Angular de 0,6499 traduz o impacto orçamentário real: para o grupo de passageiros subsidiados, para cada **R\$ 1,00 de acréscimo** concedido no valor nominal das tarifas de transporte (VI_linha), o poder público assume automaticamente um custo médio adicional de **R\$ 0,65** em subsídios diretos.

O intercepto negativo de -2,1285 delimita matematicamente o patamar mínimo tarifário a partir do qual as políticas de desconto e integração do Bilhete Único começam a operar com eficiência sobre o custo de locomoção.

6. ENCERRAMENTO E CONSIDERAÇÕES FINAIS

6.1 Conclusões sobre a Infraestrutura e Análise Social

A análise volumétrica via Big Data revelou a arquitetura e a distribuição de passageiros da Região Metropolitana do Rio de Janeiro por meio de uma ótica financeira e de modais, evidenciando uma clara assimetria entre o transporte segmentado e o transporte de massa:

- **Volume de Passageiros:** O transporte segmentado (ônibus convencionais, alimentadores e vans intermunicipais) atua como a verdadeira espinha dorsal de mobilidade em volume bruto de tráfego, registrando **2.498.257 viagens**, o que representa cerca de 3,3 vezes mais passageiros transportados do que o sistema ferroviário, metroviário e hidroviário de massa unificados (que registraram 760.098 validações no período);
- **Alocação de Recursos de Subsídio:** No período de 3 dias, o Estado destinou **R\$ 7.081.566,70** para subsidiar o transporte segmentado, enquanto o transporte de massa recebeu o aporte de **R\$ 1.383.264,15**;
- **Custo por Viagem:** Embora o transporte de massa registre uma proporção percentual de viagens subsidiadas maior (60,42% das suas viagens totais recebem algum benefício) em relação ao segmentado (39,77%), **o custo médio por viagem é sensivelmente menor no transporte de massa** (subsídio médio de R\$ 1,82 por viagem) do que no segmentado (subsídio médio de R\$ 2,83 por viagem).
Esta constatação explica-se pela natureza das integrações: no transporte ferroviário e metroviário, o subsídio se concentra no desconto fixo de integração temporal, ao passo que no segmentado (que engloba linhas de ônibus rodoviários da Baixada Fluminense e vans de tarifas elevadas), o governo arca com a diferença direta entre o teto do Bilhete Único (R\$ 9,40) e a tarifa cheia nominal da linha, elevando o gasto médio por passageiro. Em suma, os dados de Big Data provam que **transportar 1 milhão de pessoas pelo sistema de massa custa aos cofres públicos cerca de R\$ 1 milhão a menos em subsídios** do que transportar a mesma quantidade através do

sistema segmentado (uma economia de 36% por milhão de viagens), demonstrando a urgência na priorização de políticas de expansão de modais ferroviários e metroviários de alta capacidade.

6.2 Considerações finais.

A higienização profunda dos dados de ETL foi um sucesso, demonstrando que auditorias financeiras automáticas baseadas em Python barram distorções volumétricas graves (como as mais de 1,2 milhão de linhas inconsistentes expurgadas). A modelagem por regressão linear se mostrou uma ferramenta preditiva poderosa de inteligência de negócios, permitindo que gestores públicos estimem com exatidão o impacto financeiro de futuros reajustes tarifários sobre as contas do Tesouro Municipal e Estadual. Como recomendação extensionista para o aprimoramento contínuo das políticas públicas de mobilidade, sugere-se a evolução deste projeto de Big Data por meio do cruzamento das matrizes financeiras atuais com dados de geolocalização por satélite (GPS) acoplados aos validadores de bilhetagem. Tal integração viabilizará a correlação exata entre os subsídios estatais pagos e a distância real percorrida em quilômetros, abrindo caminho para a formulação de modelos de remuneração de transporte baseados na eficiência do deslocamento por passageiro/quilômetro.